




Inteligencia Artificial



Unidad 2: Redes Neuronales

TEMA 3: Algoritmos de IA Moderna-I

Módulo 2: Desde el Perceptrón a las Redes Neuronales



Unidad 2

Redes Neuronales

TEMA 3: Algoritmos de IA Moderna-
I

Sesión 11-12

MÓDULO 2: Desde el Perceptrón a las Redes Neuronales



Contenido

1. Perceptrón vs. Red Neuronal Artificial
2. Estructura de una Red Neuronal Artificial
3. Modelo Estándar de una Red Neuronal Artificial
4. El Perceptrón Simple
5. Redes ADALINE
6. Ventajas / Limitaciones



Preguntas

Aprendizaje supervisado

- El aprendizaje supervisado es una técnica aplicado en aprendizaje automático y minería de datos.
- El objetivo del aprendizaje supervisado es clasificar o predecir el valor correspondiente a cualquier objeto de entrada válida después de haber visto una serie de ejemplos denominado datos de entrenamiento. Para ello, tiene que generalizar a partir de los datos presentados a las situaciones no vistas previamente denominado test o prueba.

Clasificación vs Predicción

- ❑ Clasificación



- ❑ Usado para predecir el valor de un atributo categórico (discreto o nominal)

- ❑ Predicción


- ❑ Usado para modelar funciones que toman valores continuos
 - ❑ Predecir valores numéricos desconocidos

Aprendizaje Supervisado


CONJUNTO DE ENTRENAMIENTO



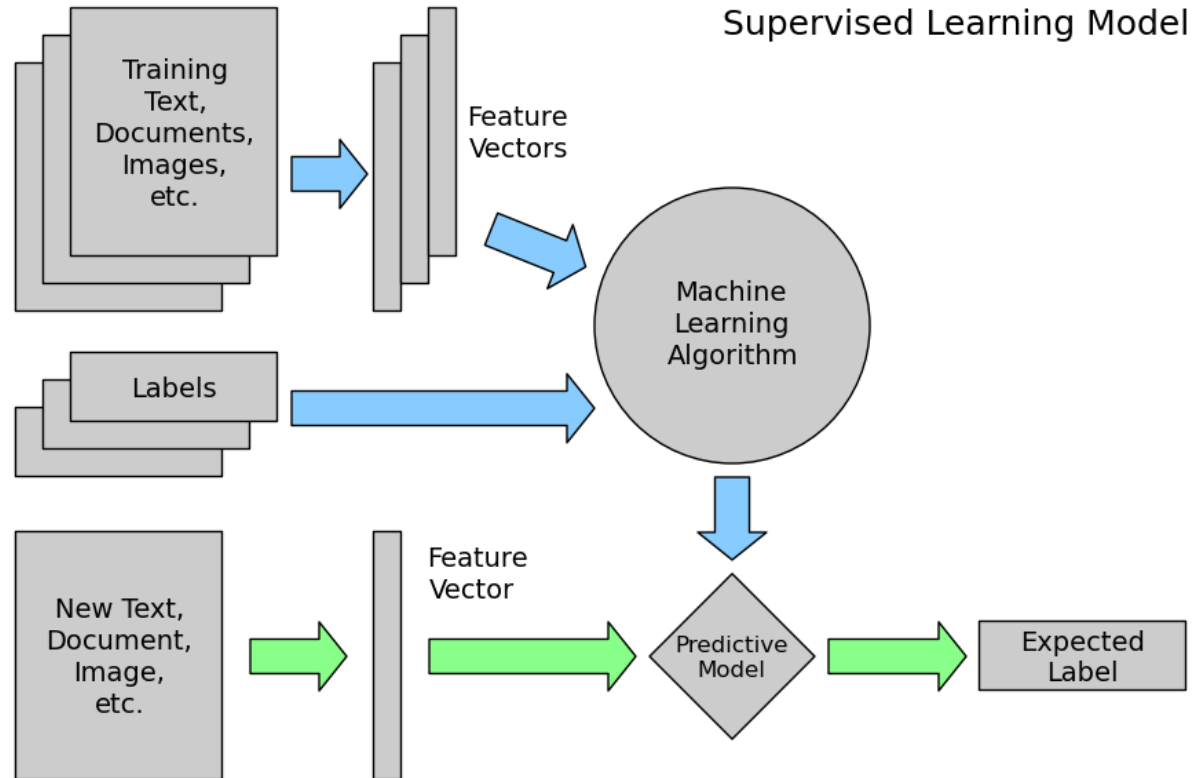
CONJUNTO DE TEST



RESULTADO



Modelo supervisado

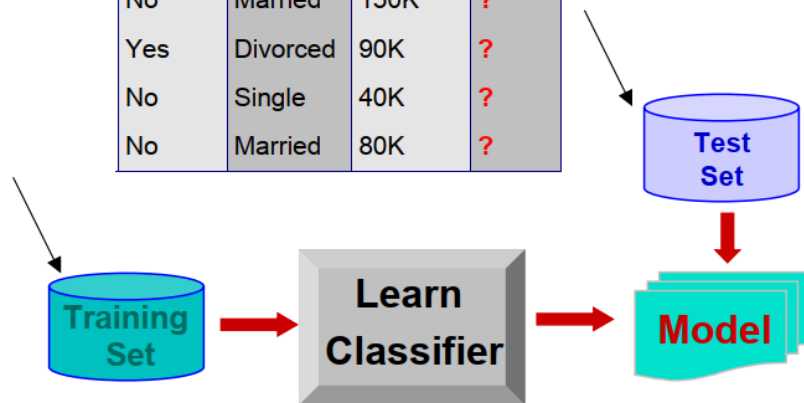


Tarea de clasificación

Ejemplo: predicción de engaños al fisco

| Tid | Refund | Marital Status | Taxable Income | Cheat |
|-----|--------|----------------|----------------|-------|
| 1 | Yes | Single | 125K | No |
| 2 | No | Married | 100K | No |
| 3 | No | Single | 70K | No |
| 4 | Yes | Married | 120K | No |
| 5 | No | Divorced | 95K | Yes |
| 6 | No | Married | 60K | No |
| 7 | Yes | Divorced | 220K | No |
| 8 | No | Single | 85K | Yes |
| 9 | No | Married | 75K | No |
| 10 | No | Single | 90K | Yes |

| Refund | Marital Status | Taxable Income | Cheat |
|--------|----------------|----------------|-------|
| No | Single | 75K | ? |
| Yes | Married | 50K | ? |
| No | Married | 150K | ? |
| Yes | Divorced | 90K | ? |
| No | Single | 40K | ? |
| No | Married | 80K | ? |



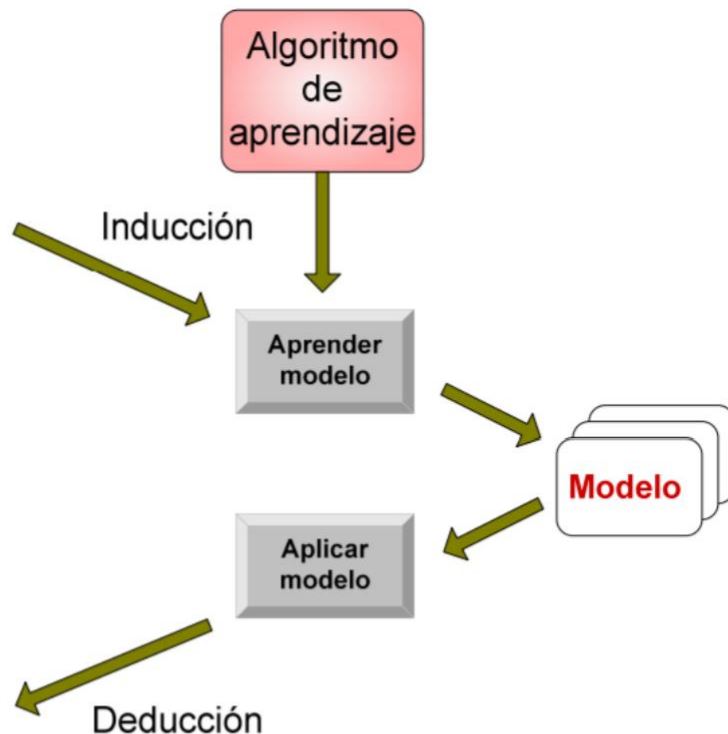
Modelo de clasificación o modelo de predicción


| Tid | Attrib1 | Attrib2 | Attrib3 | Class |
|-----|---------|---------|---------|-------|
| 1 | Yes | Large | 125K | No |
| 2 | No | Medium | 100K | No |
| 3 | No | Small | 70K | No |
| 4 | Yes | Medium | 120K | No |
| 5 | No | Large | 95K | Yes |
| 6 | No | Medium | 60K | No |
| 7 | Yes | Large | 220K | No |
| 8 | No | Small | 85K | Yes |
| 9 | No | Medium | 75K | No |
| 10 | No | Small | 90K | Yes |

Conjunto de entrenamiento


| Tid | Attrib1 | Attrib2 | Attrib3 | Class |
|-----|---------|---------|---------|-------|
| 11 | No | Small | 55K | ? |
| 12 | Yes | Medium | 80K | ? |
| 13 | Yes | Large | 110K | ? |
| 14 | No | Small | 95K | ? |
| 15 | No | Large | 67K | ? |

Conjunto de prueba








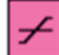





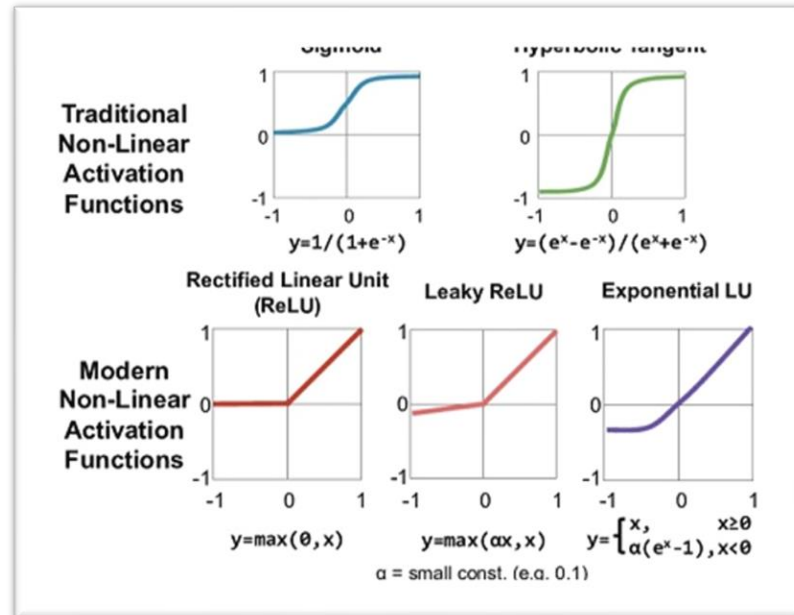
Arquitectura de la neurona artificial




Funciones de activación para la neurona

| Nombre | Relación Entrada /Salida | Icono |
|----------------------------------|--|---|
| Limitador Fuerte | $a = 0 \quad n < 0$ $a = 1 \quad n \geq 0$ |  |
| Limitador Fuerte Simétrico | $a = -1 \quad n < 0$ $a = +1 \quad n \geq 0$ |  |
| Lineal Positiva | $a = 0 \quad n < 0$ $a = n \quad 0 \leq n$ |  |
| Lineal | $a = n$ |  |
| Lineal Saturado | $a = 0 \quad n < 0$ $a = n \quad 0 \leq n < 1$ $a = 1 \quad n > 1$ |  |

| Nombre | Relación Entrada /Salida | Icono |
|--------------------------------------|---|--|
| Lineal Saturado Simétrico | $a = -1 \quad n < -1$ $a = n \quad -1 \leq n \leq 1$ $a = +1 \quad n > 1$ |  |
| Sigmoidal Logarítmico | $a = \frac{1}{1 + e^{-n}}$ |  |
| Tangente Sigmoidal Hiperbólica | $a = \frac{e^n - e^{-n}}{e^n + e^{-n}}$ |  |
| Competitiva | $a = 1$ Neurona con n max $a = 0$ el resto de neuronas |  |



Funciones de activación para la neurona




Algoritmo de Perceptron unicapa

1. Iniciar valores aleatorios para pesos y umbral
2. Modificación de los pesos hasta encontrar el hiperplano discriminante
 - a) Seleccionar un ejemplo x del conjunto de entrenamiento
 - b) Se calcula la salida de la red:
$$a = w_1x_1 + w_2x_2, \dots, w_nx_n + w_0$$
$$y = f(a)$$
 - c) Si $y \neq d(x)$ se modifican los pesos:
$$w_i(t+1) = w_i(t) + \alpha(d(x) - y) * x_i$$
 - d) Repetir épocas desde el paso 2.a hasta cumplir un criterio de parada.


Donde:

- α es factor de aprendizaje
- $d(x)$ clase o etiqueta esperada

| Tid | Attrib1 | Attrib2 | Attrib3 | Class |
|-----|---------|---------|---------|-------|
| 1 | Yes | Large | 125K | No |
| 2 | No | Medium | 100K | No |
| 3 | No | Small | 70K | No |
| 4 | Yes | Medium | 120K | No |
| 5 | No | Large | 95K | Yes |
| 6 | No | Medium | 60K | No |
| 7 | Yes | Large | 220K | No |
| 8 | No | Small | 85K | Yes |
| 9 | No | Medium | 75K | No |
| 10 | No | Small | 90K | Yes |



Objetivo de Perceptrón Unicapa



Usa una función de activación
ejemplo limitador fuerte simétrico


$$y = \begin{cases} +1, & \text{si } a > 0 \\ -1, & \text{si } a \leq 0 \end{cases}$$

La ecuación del hiperplano es: $w_1 x_1 + w_2 x_2 + \theta = 0$

$$x_2 = -\left(\frac{w_1}{w_2}\right)x_1 - \left(\frac{\theta}{w_2}\right)$$

Pendiente de la recta

Punto de corte



Perceptrón Simple: Ejemplo

Considerar el conjunto de datos

Factor de aprendizaje $\alpha = 0.3$

| Atributos | | | Clase |
|-----------|-------|-------|-------|
| | X_1 | X_2 | |
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| ... | ... | ... | ... |
| n | ... | ... | ... |


1. Diseñar la Red Neuronal que corresponde
2. Presentar el hiperplano discriminante de clasificación previo a entrenamiento
3. Realizar el entrenamiento
4. Presentar el hiperplano discriminante de clasificación posterior al entrenamiento

Perceptrón Simple: Ejemplo- Solución

1) Diseñar la Red Neuronal

Conjunto de datos

| Atributos | | | Clase |
|-----------|-------|-------|-------|
| | x_1 | x_2 | |
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| .. | ... | | ... |
| n | | | |



Perceptrón Simple: Ejemplo- Solución


2) Presentar el hiperplano discriminante de clasificación previo a entrenamiento

Conjunto de datos

| | Atributos | | Clase |
|----|-----------|-------|-------|
| | x_1 | x_2 | |
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| .. | ... | | ... |
| n | | | |

Considerar la ecuación:

$$w_1 x_1 + w_2 x_2 + \theta = 0$$




Hallamos un punto

Asumimos $x_1 = -1$

$$(1)(-1) + (1)x_2 + 0.5 = 0$$

$$x_2 = 1 - 0.5$$


$$x_2 = 0.5$$



Solución Perceptrón Simple Solución


3) Realizar el entrenamiento con el primer patrón

Conjunto de datos

a) 

| | x_1 | x_2 | Clase |
|-----|-------|-------|-------|
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| ... | ... | | ... |
| n | | | |

$$x = (-1, -1),$$
$$d(x) = -1$$



$$f(x) \Rightarrow$$

$$y = \begin{cases} +1, & \text{si } w_1x_1 + w_2x_2 + \theta > 0 \\ -1, & \text{si } w_1x_1 + w_2x_2 + \theta \leq 0 \end{cases}$$

b)

$$a = w_1x_1 + w_2x_2 + w_0x_0$$
$$a = (1)(-1) + (1)(-1) + (0.5)(1)$$
$$a = -1.5$$

$$y = d(x) = ?$$
$$y = f(-1.5) = -1$$

c) Bien clasificado
No modificamos pesos


Entrenando Perceptrón Simple - Solución

4) Realizar el entrenamiento con el segundo patrón

Conjunto de datos

a) ➡

| | x_1 | x_2 | Clase |
|-----|-------|-------|-------|
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| ... | ... | ... | ... |
| n | ... | ... | ... |



$$f(x) \Rightarrow y = \begin{cases} +1, & \text{si } w_1x_1 + w_2x_2 + \theta > 0 \\ -1, & \text{si } w_1x_1 + w_2x_2 + \theta \leq 0 \end{cases}$$

Factor de aprendizaje $\alpha = 0.3$

b)

$$\left\{ \begin{array}{l} a = w_1x_1 + w_2x_2 + w_0x_0 \\ a = (1)(1) + (1)(-1) + (0.5)(1) \\ a = 0.5 \\ y = f(0.5) = 1 \\ y = d(x) = \mathbf{F} \end{array} \right.$$

Mal clasificado (nuevos pesos)

c)

$$\left\{ \begin{array}{l} w_i(t+1) = w_i(t) + \alpha(d(x) - y) * x_i \\ w_1 = 1 + 0.3(-1 - 1)1 = 0.4 \\ w_2 = 1 + 0.3(-1 - 1) - 1 = 1.6 \\ \theta = 0.5 + 0.3(-1 - 1)1 = -0.1 \end{array} \right.$$


Entrenando Perceptrón Simple - Solución

4) Realizar el entrenamiento con el segundo patrón

Conjunto de datos

| | x_1 | x_2 | Clase |
|----|-------|-------|-------|
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| .. | ... | | ... |
| n | | | |

a) ➡



$$y = \begin{cases} +1, & \text{si } w_1x_1 + w_2x_2 + \theta > 0 \\ -1, & \text{si } w_1x_1 + w_2x_2 + \theta \leq 0 \end{cases}$$

Factor de aprendizaje $\alpha = 0.3$

b) {


$$\begin{aligned} a &= w_1x_1 + w_2x_2 + w_0x_0 \\ a &= (0,4)(1) + (1,6)(-1) + (-0,1)(1) \\ a &= 0,4 - 1,6 - 0,1 \\ y &= f(-1, 3) = -1 \\ y &= d(x) = V \end{aligned}$$

c)

Bien clasificado
No modificamos pesos

Resultado de entrenamiento

Después de entrenar 2 patrones



Considerar la ecuación:

$$w_1 x_1 + w_2 x_2 + \theta = 0$$

Hallamos un punto

Asumimos $x_1 = -1$

$$(0.4)(-1) + (1.6)x_2 - 0.1 = 0$$

$$x_2 = (0.4 + 0.1)/1.6$$

$$x_2 = 0.313$$


Hallamos el otro punto

Asumimos $x_1 = 1$

$$(0.4)(1) + (1.6)x_2 - 0.1 = 0$$

$$x_2 = (-0.4 + 0.1)/1.6$$

$$x_2 = 0.186$$




Entrenando Perceptrón Simple - Solución

4) Realizar el entrenamiento con el tercer patrón

Conjunto de datos

| | x_1 | x_2 | Clase |
|-----|-------|-------|-------|
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| ... | ... | ... | ... |
| n | ... | ... | ... |

a) ➡



b) $\left\{ \begin{array}{l} a = w_1x_1 + w_2x_2 + w_0x_0 \\ a = (0,4)(-1) + (1,6)(1) + (-0,1)(1) \\ a = 1,1 \\ y = f(0.5) = 1 \\ y = d(x) = \mathbf{F} \end{array} \right.$

Mal clasificado (nuevos pesos)

c) $\left\{ \begin{array}{l} w_i(t+1) = w_i(t) + \alpha(d(x) - y) * x_i \\ w_1 = 0,4 + 0.3(-1 - 1)(-1) = 1 \\ w_2 = 1,6 + 0.3(-1 - 1)(+1) = 1 \\ \theta = -0,1 + 0.3(-1 - 1)1 = -0.7 \end{array} \right.$


Entrenando Perceptrón Simple - Solución

4) Realizar el entrenamiento con el tercer patrón

Conjunto de datos

| | x_1 | x_2 | Clase |
|----|-------|-------|-------|
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| .. | ... | | ... |
| n | | | |

a) ➡



b)
$$\begin{cases} a = w_1x_1 + w_2x_2 + w_0x_0 \\ a = (1)(-1) + (1)(1) + (-0,7)(1) \\ a = -0,7 \\ y = f(-0,7) = -1 \\ y = d(x) = V \end{cases}$$

c) **Bien clasificado**
No modificamos pesos


Entrenando Perceptrón Simple - Solución

4) Realizar el entrenamiento con el cuarto patrón

Conjunto de datos

| | x_1 | x_2 | Clase |
|----|-------|-------|-------|
| 1 | -1 | -1 | -1 |
| 2 | 1 | -1 | -1 |
| 3 | -1 | 1 | -1 |
| 4 | 1 | 1 | 1 |
| .. | ... | | ... |
| n | | | |

a) ➡



b)
$$\begin{cases} a = w_1x_1 + w_2x_2 + w_0x_0 \\ a = (1)(1) + (1)(1) + (-0,7)(1) \\ a = 1,3 \\ y = f(1.3) = 1 \\ y = d(x) = V \end{cases}$$

c) **Bien clasificado**
No modificamos pesos

5. Redes ADALINE

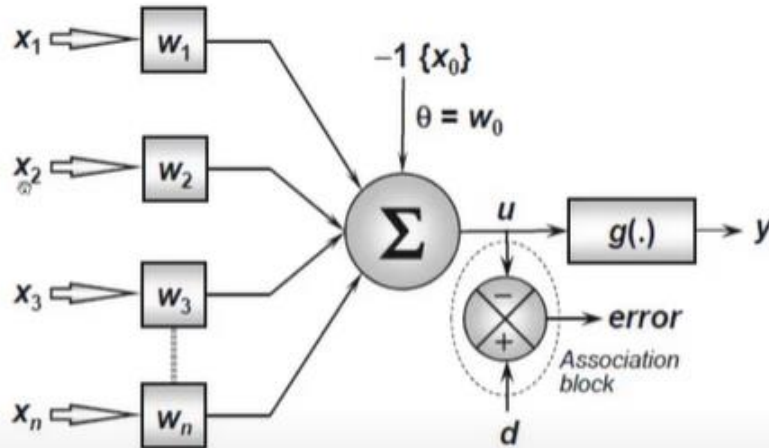
ADALINE (ADaptive Linear NEuron) fue desarrollado en 1960 por Widrow y Hoff.

- Las entradas pueden ser continuas y se utiliza una neurona similar a la del Perceptrón Simple, igualmente, resulta un caso de respuesta lineal.



Dr. Bernard Widrow

PhD. Marcian Hoff



$$u = \sum_{i=1}^n w_i * x_i - \theta \longleftrightarrow u = \sum_{i=0}^n w_i * x_i$$

5. Redes ADALINE

ADALINE (ADaptive Linear NEuron) fue desarrollado en 1960 por Widrow y Hoff.

- La salida de la Red Adaline se puede dar mediante la ecuación:

$$u = \sum_{i=1}^n w_i * x_i - \theta \longleftrightarrow u = \sum_{i=0}^n w_i * x_i$$

$$y = g(u)$$

- x_i son las señales de entrada a la red ADALINE.
- w_i son los pesos sinápticos asociados a cada entrada.
- θ es el umbral de activación o bias.
- $g()$ es la función de activación.
- u es el potencial de activación.



Dr. Bernard Widrow



PhD. Marcian Hoff

5. Redes ADALINE

APRENDIZAJE: DIFERENCIAS ENTRE PERCEPTRON Y REDES ADALINE

PERCEPTRON

- Utiliza la salida de la función umbral (binaria) para el aprendizaje.
- Sólo se tiene en cuenta si se ha equivocado o no (no cuanto se equivocó).
- Valores de respuesta no continuos.

ADALINE

- Utiliza directamente la salida de la red (real) teniendo en cuenta **cuánto se ha equivocado**.
- Considera el error entre la salida lograda y versus la salida deseada d (etiqueta):
$$|d^p - y^p|$$
- Esta regla se conoce como **REGLA DELTA**. La $\Delta w_i = \alpha |d^p - y^p| x_i$ constante α se denomina **TASA DE APRENDIZAJE**.
- Valores de respuesta continuos.
- Se busca minimizar la desviación de la red para todos los patrones (características) de entrada, eligiendo una medida del error global.
- Normalmente se utiliza el error cuadrático medio:

$$E = \frac{1}{2} \sum_{p=1}^m (d^p - y^p)^2$$

Error cuadrático medio, compara un valor predicho y un valor observado o conocido.


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #1: Asignamos valores aleatorios para pesos de las entradas y umbral



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento:

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 0.84 * 0 + 0.394 * 0 + 0.783 * 1 = 0.783$$

$$E = |d^p - y^p| = |1 - 0.783| = 0.217$$

Paso #4: Para todos los pesos y para el umbral, calcular:

$$w_1 = w_1 + \alpha * E * x_1 = 0.84 + 0.3 * 0.217 * 0 = 0.840$$

$$w_2 = w_2 + \alpha * E * x_2 = 0.394 + 0.3 * 0.217 * 0 = 0.394$$

$$w_3 = w_3 + \alpha * E * x_3 = 0.783 + 0.3 * 0.217 * 1 = 0.8481$$

1 =


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #5: Modificar los pesos y el umbral y repetimos desde el **paso #2** hasta cumplir el criterio de parada.



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento: $x_1 = 0$, $x_2 = 1$, $x_3 = 0$

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 0.84 * 0 + 0.394 * 1 + 0.8481 * 0 = 0.394$$

$$E = |d^p - y^p| = |2 - 0.394| = 1.606$$

Paso #4: Para todos los pesos y para el umbral, calcular:

$$w_1 = w_1 + \alpha * E * x_1 = 0.84 + 0.3 * 1.606 * 0 = 0.840$$

$$w_2 = w_2 + \alpha * E * x_2 = 0.394 + 0.3 * 1.606 * 1 = 0.876$$

$$w_3 = w_3 + \alpha * E * x_3 = 0.8481 + 0.3 * 1.606 * 0 = 0.8481$$


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #5: Modificar los pesos y el umbral y repetimos desde el **paso #2** hasta cumplir el criterio de parada.



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento: $x_1 = 0, x_2 = 1, x_3 = 1$

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 0.84 * 0 + 0.876 * 1 + 0.8481 * 1 = 1.7241$$

$$E = |d^p - y^p| = |3 - 0.394| = 1.2759$$

Paso #4: Para todos los pesos y para el umbral, calcular:

$$w_1 = w_1 + \alpha * E * x_1 = 0.84 + 0.3 * 1.2759 * 0 = 0.840$$

$$w_2 = w_2 + \alpha * E * x_2 = 0.876 + 0.3 * 1.2759 * 1 = 1.259$$

$$w_3 = w_3 + \alpha * E * x_3 = 0.8481 + 0.3 * 1.2759 * 1 = 1.231$$


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #5: Modificar los pesos y el umbral y repetimos desde el **paso #2** hasta cumplir el criterio de parada.



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento: $x_1 = 1, x_2 = 0, x_3 = 0$

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 0.84 * 1 + 0.876 * 0 + 0.8481 * 0 = 0.84$$

$$E = |d^p - y^p| = |4 - 0.84| = 3.16$$

Paso #4: Para todos los pesos y para el umbral, calcular:

$$w_1 = w_1 + \alpha * E * x_1 = 0.84 + 0.3 * 3.16 * 1 = 1.788$$

$$w_2 = w_2 + \alpha * E * x_2 = 1.259 + 0.3 * 3.16 * 0 = 1.259$$

$$w_3 = w_3 + \alpha * E * x_3 = 1.231 + 0.3 * 3.16 * 0 = 1.231$$


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #5: Modificar los pesos y el umbral y repetimos desde el **paso #2** hasta cumplir el criterio de parada.



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento: $x_1 = 1, x_2 = 0, x_3 = 1$

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 1.788 * 1 + 1.259 * 0 + 1.231 * 1 = 3.019$$

$$E = |d^p - y^p| = |5 - 3.019| = 1.981$$

Paso #4: Para todos los pesos y para el umbral, calcular:

$$w_1 = w_1 + \alpha * E * x_1 = 1.788 + 0.3 * 1.981 * 1 = 2.382$$

$$w_2 = w_2 + \alpha * E * x_2 = 1.259 + 0.3 * 1.981 * 0 = 1.259$$

$$w_3 = w_3 + \alpha * E * x_3 = 1.231 + 0.3 * 1.981 * 1 = 1.825$$


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #5: Modificar los pesos y el umbral y repetimos desde el **paso #2** hasta cumplir el criterio de parada.



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento:

$$x_1 = 1, x_2 = 1, x_3 = 0$$

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 2.382 * 1 + 1.259 * 1 + 1.825 * 0 = 3.641$$

$$E = |d^p - y^p| = |6 - 3.641| = 2.359$$

Paso #4: Para todos los pesos y para el umbral, calcular:

$$w_1 = w_1 + \alpha * E * x_1 = 2.382 + 0.3 * 2.359 * 1 = 3.09$$

$$w_2 = w_2 + \alpha * E * x_2 = 1.259 + 0.3 * 2.359 * 1 = 1.967$$

$$w_3 = w_3 + \alpha * E * x_3 = 1.825 + 0.3 * 2.359 * 0 = 1.825$$


5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Datos

| x_1 | x_2 | x_3 | $d(X)$ |
|-------|-------|-------|--------|
| 0 | 0 | 1 | 1 |
| 0 | 1 | 0 | 2 |
| 0 | 1 | 1 | 3 |
| 1 | 0 | 0 | 4 |
| 1 | 0 | 1 | 5 |
| 1 | 1 | 0 | 6 |
| 1 | 1 | 1 | 7 |

Paso #5: Modificar los pesos y el umbral y repetimos desde el **paso #2** hasta cumplir el criterio de parada.



Paso #2: Seleccionar un ejemplo x del conjunto de entrenamiento:

$$x_1 = 1, x_2 = 1, x_3 = 1$$

Paso #3: Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

$$y = 3.09 * 1 + 1.967 * 1 + 1.825 * 1 = 6.882$$

$$E = |d^p - y^p| = |7 - 6.882| = 0.118$$

Paso #4: Para todos los pesos y para el umbral, calcular:

Resultado después de la primera iteración del entrenamiento

$$w_1 = w_1 + \alpha * E * x_1 = 3.09 + 0.3 * 0.118 * 1 = 3.125$$

$$w_2 = w_2 + \alpha * E * x_2 = 1.967 + 0.3 * 0.118 * 1 = 2.002$$

$$w_3 = w_3 + \alpha * E * x_3 = 1.825 + 0.3 * 0.118 * 1 = 1.860$$

5. Redes ADALINE

EJEMPLO: Decodificador binario a decimal

Visualización de los pesos según iteraciones

| Iteración | w1 | w2 | w3 |
|-----------|------|------|------|
| 1 | 3.13 | 2.00 | 1.86 |
| 2 | 3.61 | 1.98 | 1.42 |
| 3 | 3.82 | 1.98 | 1.2 |
| 4 | 3.92 | 1.98 | 1.1 |
| 5 | 3.96 | 1.99 | 1.02 |
| 6 | 3.99 | 2.00 | 1.01 |
| 7 | 4.00 | 2.00 | 1.00 |
| 8 | 4.00 | 2.00 | 1.00 |
| 9 | 4.00 | 2.00 | 1.00 |
| 10 | 4.00 | 2.00 | 1.00 |

- La tasa de aprendizaje α también puede ser adaptativa.
- Por ejemplo al inicio, el valor puede ser alto, para dar “grandes pasos” de corrección del error y para salir de mínimos locales.
- Sin embargo al final del entrenamiento debe disminuir para hacer correcciones finas.

5. Redes ADALINE

APRENDIZAJE: Seudocódigo

1. Inicializar los pesos y umbral de forma aleatoria.
2. Seleccionar un ejemplo x del conjunto de entrenamiento.
3. Calcular la salida de la red: $y = f(w_1x_1 + \dots + w_nx_n + \theta)$ y obtener la diferencia.

4. Para todos los pesos y para el umbral, calcular:

$$\Delta w_i = \alpha |d^p - y^p| x_i \quad \Delta \theta_i = \alpha |d^p - y^p|$$

5. Modificar los pesos y el umbral del siguiente modo:

$$w_i(t+1) = w_i(t) + \Delta w_i$$

$$\theta(t+1) = \theta(t) + \Delta \theta_i$$

6. Repetir para todos los patrones de entrenamiento hasta cumplir el criterio de parada.

6. Ventajas / Limitaciones

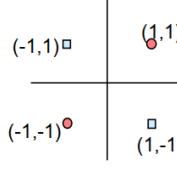
VENTAJAS

- El uso del Perceptrón o de las redes ADALINE permite aproximar de manera fácil, cualquier tipo de función o sistemas, sólo conociendo un conjunto de ejemplos (características o entradas).
- El uso del Perceptrón o de las redes ADALINE permite que cualquier sistema (caja negra), se puede representar por una red.

LIMITACIONES

- Estas técnicas poseen grandes limitaciones.
- Sólo pueden resolver sistemas donde los ejemplos o características (entradas) son linealmente separables (por ejemplo no resolverá el XOR Exclusivo para el cual no existe un hiperplano).

| x_1 | x_2 | $d(x)$ |
|-------|-------|--------|
| -1 | -1 | 1 |
| -1 | 1 | -1 |
| 1 | -1 | -1 |
| 1 | 1 | 1 |



Solución: Combinar varios Perceptrones

PREGUNTAS

Dudas y opiniones

Preguntas?